UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

Projet PF22

RAPPORT DE PROJET

Réduction des Coûts d'Apprentissage par Approche Multi-Fidélité

Ce projet explore la possibilité de réduire drastiquement les coûts de constitution d'un jeu de données en combinant une faible proportion d'images **Haute Fidélité** avec une grande majorité d'images **Basse Fidélité** acquises à moindre coût.

Auteur : Ivann Vasic
Période : Mars – Juin 2026
Cadre : Projet PF22 — UTBM

Résumé

L'entraînement de modèles d'apprentissage profond performants nécessite traditionnellement de vastes ensembles de données de haute qualité, dont l'acquisition et l'annotation s'avèrent souvent coûteuses en temps et en ressources. Ce projet explore une approche alternative : **l'apprentissage multi-fidélité**.

L'objectif est de démontrer qu'il est possible de réduire drastiquement les coûts de constitution d'un jeu de données en combinant une faible proportion d'images de **Haute Fidélité (HF)** avec une grande majorité d'images dégradées acquises à moindre coût (**Basse Fidélité - BF**).

Mots-clés : Apprentissage profond · Multi-fidélité · CNN · ResNet-18 · Dégradation d'image · Optimisation des coûts · Domain Shift · Animals-10

Table des matières

1 Notions Préliminaires **4**

1.1 Les réseaux de neurones artificiels 4

1.2 Paramètres et poids du réseau 4

1.3 La boucle d'entraînement 5

1.3.1 La fonction de perte 5

1.3.2 La descente de gradient et l'optimiseur 5

1.4 Hyperparamètres clés 6

1.5 Sous-apprentissage, sur-apprentissage et généralisation 6

1.6 Les différentes dimensions du coût en apprentissage profond 7

2 Fondation et construction de l'environnement Multi-Fidélité **8**

2.1 Environnement de travail et architecture hybride 8

2.2 Sélection du jeu de données 8

2.3 Découpage et répartition des données 9

2.4 Pipeline de dégradation de la qualité 10

2.5 Définition de la métrique de coût 10

2.6 Sélection et justification de l'architecture neuronale 10

2.6.1 Mécanique interne de ResNet-18 11

2.6.2 Justification des hyperparamètres et de la fonction de coût 11

2.6.3 Prétraitement et optimisations matérielles 12

3 Construction des Modèles de Référence **13**

3.1 Stratégie d'évaluation croisée face au décalage de domaine 13

3.2 Définition des modèles de référence 13

3.3 Stratégie d'implémentation logicielle 14

3.4 Analyse des résultats 14

CHAPITRE 1

Notions Préliminaires

Ce chapitre présente les concepts fondamentaux nécessaires à la compréhension du projet. Le lecteur familier avec l'apprentissage profond peut passer directement au Chapitre 2.

1.1 Les réseaux de neurones artificiels

Un réseau de neurones artificiel est un système de calcul inspiré du cerveau biologique. Il est constitué d'unités élémentaires, les **neurones**, organisées en **couches** successives. Chaque neurone reçoit des signaux numériques en entrée, les combine linéairement, puis applique une **fonction d'activation** non-linéaire avant de transmettre le résultat à la couche suivante.

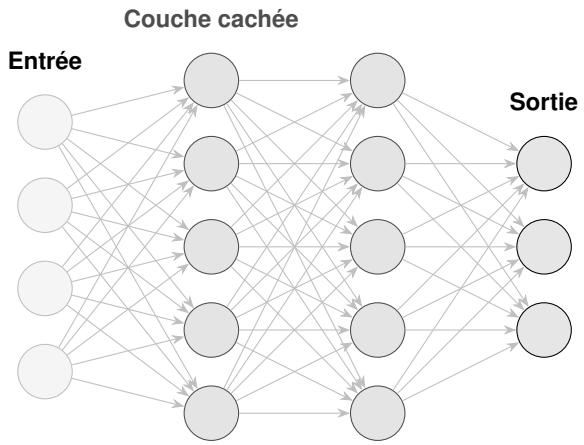

L'empilement de plusieurs couches cachées constitue un réseau dit **profond** (*deep network*). La profondeur permet au réseau d'apprendre des représentations de plus en plus abstraites : les premières couches détectent des motifs simples (contours, textures), tandis que les couches profondes reconnaissent des concepts complexes (forme d'un animal, expression d'un visage).

1.2 Paramètres et poids du réseau

Les connexions entre neurones sont régies par des valeurs numériques appelées **poids** (w) et **biais** (b). Ce sont les **paramètres apprenables** du réseau : ils sont initialisés aléatoirement, puis ajustés itérativement au cours de l'entraînement.

Paramètre	Rôle	Interprétation
Poids w_{ij}	Pondère la connexion entre le neurone i et j	Fort poids $\Rightarrow$ le signal du neurone i influence fortement j
Biais b_j	Décale le seuil d'activation du neurone j	Permet au neurone de s'activer même en absence de signal fort

Un réseau comme ResNet-18 possède environ **11 millions de paramètres**. La qualité de l'apprentissage dépend de la capacité à trouver les valeurs optimales de l'ensemble de ces paramètres.

1.3 La boucle d'entraînement

L'entraînement d'un réseau de neurones est un processus itératif qui suit quatre étapes fondamentales, répétées pour chaque lot (*batch*) d'images :

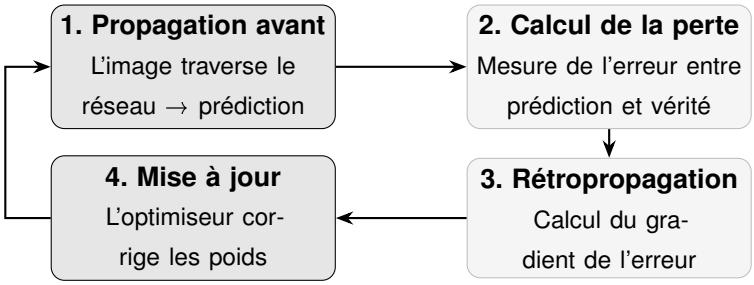

Une **époque** (*epoch*) correspond au passage complet de l'intégralité du jeu de données d'entraînement à travers cette boucle. L'entraînement se déroule sur plusieurs dizaines d'époques jusqu'à convergence.

1.3.1 La fonction de perte

La **fonction de perte** (*loss function*) quantifie l'écart entre la prédiction du réseau et la vérité terrain. Plus la perte est faible, plus le modèle est précis. Pour la classification multi-classes, la **Entropie Croisée** (*Cross-Entropy Loss*) est le standard :

$$\mathcal{L} = -\sum_{c=1}^{C} y_c \cdot \log(\hat{p}_c)$$

où C est le nombre de classes, y_c la vraie étiquette (0 ou 1), et $\hat{p}_c$ la probabilité prédite par le réseau pour la classe c.

1.3.2 La descente de gradient et l'optimiseur

La **rétropropagation** calcule, pour chaque paramètre du réseau, le gradient de la perte : une mesure indiquant dans quelle direction et de quelle amplitude modifier ce paramètre pour réduire l'erreur.

L'**optimiseur** utilise ensuite ces gradients pour mettre à jour les poids :

$$w \leftarrow w - \eta \cdot \nabla_w \mathcal{L}$$

où η est le **taux d'apprentissage** (*learning rate*), un hyperparamètre critique qui contrôle la taille du pas de correction. Un η trop grand risque de faire diverger l'apprentissage ; trop petit, la convergence devient extrêmement lente.

1.4 Hyperparamètres clés

Contrairement aux poids, les **hyperparamètres** ne sont pas appris automatiquement : ils doivent être fixés manuellement avant l'entraînement et conditionnent fortement la qualité du résultat final.

Hyperparamètre	Définition	Impact
Taux d'apprentissage η	Amplitude du pas de correction	Trop grand : divergence. Trop petit : apprentissage lent ou bloqué.
Taille de lot (*batch size*)	Nombre d'images traitées simultanément	Influence la stabilité du gradient et l'utilisation mémoire du GPU.
Nombre d'époques	Nombre de passages complets sur les données	Trop faible : sous-apprentissage. Trop élevé : mémorisation (*overfitting*).
Architecture	Nombre et type de couches	Détermine la capacité d'abstraction et la vitesse d'inférence.

1.5 Sous-apprentissage, sur-apprentissage et généralisation

L'objectif de l'entraînement n'est pas de mémoriser parfaitement les données d'entraînement, mais de **généraliser** : être capable de classer correctement des images jamais vues. Deux pathologies opposées peuvent survenir :

Phénomène	Cause	Symptôme
Sous-apprentissage (*Underfitting*)	Réseau trop simple ou entraînement trop court	Mauvaises performances aussi bien en entraînement qu'en test.
Sur-apprentissage (*Overfitting*)	Réseau trop complexe ou trop peu de données	Excellentes performances en entraînement, chute sévère en test.

Le découpage systématique du jeu de données en un ensemble d'**entraînement** et un ensemble de **test** (jamais utilisé pendant l'apprentissage) permet de détecter ces phénomènes et de mesurer objectivement la généralisation du modèle.

1.6 Les différentes dimensions du coût en apprentissage profond

En apprentissage profond industriel, le terme « coût » recouvre trois réalités distinctes qu'il convient de ne pas confondre :

#	Type de coût	Nature	Exemples concrets
1	**Coût de la donnée**	Acquisition et annotation du jeu de données	Photographe professionnel, expert annotateur humain, équipement haute résolution.
2	**Coût de calcul**	Temps GPU nécessaire à l'entraînement	Location d'instances cloud, consommation électrique, durée d'entraînement.
3	**Coût de déploiement**	Inférence en production	Taille du modèle, latence de prédiction, mémoire requise.

Ce projet se concentre prioritairement sur le **Coût de la donnée** (type 1), qui représente le verrou économique principal dans la plupart des applications industrielles réelles. La métrique de **Crédit d'Annotation (CA)**, définie au Chapitre 1, permet de quantifier ce coût de manière rigoureuse et indépendante du matériel utilisé.

Résumé des notions clés

Un réseau de neurones apprend en ajustant itérativement ses **poids** pour minimiser une **fonction de perte**, via la **rétropropagation du gradient**. La qualité de cet apprentissage dépend des **hyperparamètres**, du **volume** et de la **qualité** des données d'entraînement. L'enjeu central de ce projet est de démontrer qu'il est possible de réduire le **coût d'acquisition des données** sans sacrifier les performances de généralisation.

CHAPITRE 2

Fondation et construction de l'environnement Multi-Fidélité

Les choix et la mise en place de l'environnement de travail ont été guidés par des contraintes matérielles et par la nécessité de disposer de données adaptées à la simulation d'une approche multi-fidélité.

2.1 Environnement de travail et architecture hybride

Une **architecture hybride déportée** a été conçue, alliant faible coût et haute efficacité, en cohérence directe avec la thématique du projet.

Outil	Rôle	Détail
VS Code	IDE local	Écriture du code, gestion des terminaux et suivi de projet
Google Colab	Calcul distant	GPU NVIDIA T4 cloud, connecté directement à VS Code via extension sécurisée
Google Drive	Stockage persistant	Monté à chaque session ; héberge le dataset et sauvegarde les *checkpoints* par époque
GitHub	Versioning	Contrôle de version et sauvegarde du code source expérimental

Un script de test d'intégration a été développé pour valider cette synergie. Il a mis en évidence un **goulot d'étranglement réseau (I/O Bottleneck)** lors de la lecture de milliers de fichiers via le protocole FUSE de Drive, résolu par l'extraction locale d'archives ZIP directement sur le SSD de l'instance Colab.

2.2 Sélection du jeu de données

Le jeu de données doit être suffisamment difficile pour que la dégradation visuelle impacte mesurément les performances du réseau. Quatre candidats ont été évalués :

Dataset	Images	Avantages	Inconvénients
Imagenette	13 000	Standard académique, itérations rapides	Trop « facile » pour ResNet-18 (≈95% sans dégradation)
STL-10	105 000	Grand jeu non étiqueté (100k images)	Résolution native 96×96 trop faible
Oxford Pets	7 400	Classification fine-grained, très sensible aux dégradations	Volume insuffisant, nécessite un pré-entraînement lourd
Animals-10	**26 179**	**Haute résolution, volume idéal, proche des conditions réelles**	Bruit de labels et filigranes (peuvent être corrigés)

Choix retenu : Animals-10

Son volume (26 179 images après nettoyage) permet un entraînement *from scratch* stable avec ResNet-18. Sa haute résolution native offre une large plage dynamique pour le pipeline de dégradation. Son caractère communautaire le rapproche des conditions industrielles réelles.

2.3 Découpage et répartition des données

Afin d'étudier l'impact de la qualité des données sur les performances d'apprentissage, un environnement expérimental a été construit : découpage asymétrique du dataset, pipeline de dégradation et métrique de coût. Le schéma ci-dessous illustre le découpage du jeu Animals-10.

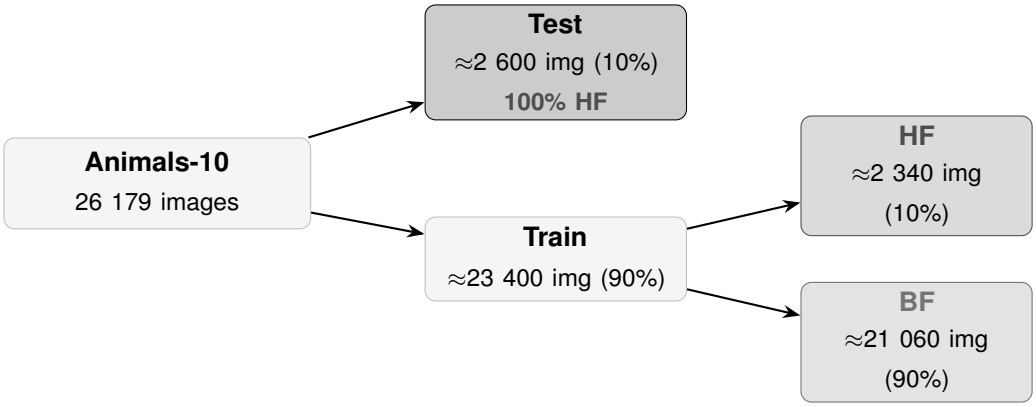

Principe clé

Le jeu de **test est exclusivement HF** pour toutes les expériences : l'évaluation doit mesurer la capacité de généralisation sur des données de haute qualité, quel que soit le domaine utilisé à l'entraînement.

2.4 Pipeline de dégradation de la qualité

La génération des images Basse Fidélité applique deux transformations consécutives **à la volée** :

#	Transformation	Description	Effet simulé
1	Sous-échantillonnage (*Downsampling*)	Réduction à 64×64 px puis redimensionnement à 224×224 px par interpolation bilinéaire	Perte d'information : image floue et pixélisée
2	Bruit Gaussien	Ajout d'un bruit aléatoire (grain) aux tenseurs de l'image	Simulation du bruit ISO des capteurs électroniques

2.5 Définition de la métrique de coût

Type d'image	Coût	Justification
Haute Fidélité (C_{HF})	**10 CA**	Expert humain ou équipement onéreux
Basse Fidélité (C_{BF})	**1 CA**	Collecte automatisée, pré-étiquetage web

Pourquoi pas le temps de calcul ?

Le temps de calcul brut ($Temps_{Epoch} \times Nombre_{Epochs}$) a été écarté en raison de l'instabilité des environnements cloud (fluctuations de charge serveur, allocation dynamique GPU, goulots I/O). Le **Crédit d'Annotation** offre un référentiel **invariant, agnostique au matériel**, centré sur la valeur intrinsèque de la donnée.

2.6 Sélection et justification de l'architecture neuronale

Pour que la comparaison entre nos différents jeux de données (HF, BF, Mixte) soit scientifiquement valide, l'architecture doit rester strictement identique. Plusieurs architectures standards de vision par ordinateur ont été évaluées :

Architecture	Paramètres	Points forts	Limites / Pertinence
ResNet-18 ✓	≈11 M	Standard académique, connexions résiduelles, robuste au bruit.	**Pertinence excellente** — compromis idéal.
MobileNetV2	≈3,4 M	Ultra-léger, économe en VRAM, itérations rapides.	S'effondre sur données fortement bruitées.
EfficientNet-B0	≈5,3 M	Ratio précision/paramètres optimisé mathématiquement.	Difficile à faire converger *from scratch*.
ViT-Tiny	≈5 M	Architecture Transformer, vision globale.	Sur-apprend massivement sans pré-entraînement.

Architecture retenue : ResNet-18 (Entraîné *from scratch*)

Ses ≈11 millions de paramètres lui confèrent une capacité d'abstraction suffisante pour extraire des caractéristiques à travers le bruit. Il a été délibérément choisi de ne pas utiliser de poids pré-entraînés (`weights=None`) afin de mesurer le véritable impact qualitatif de notre jeu de données Animals-10 sur l'apprentissage, sans biais cognitif préalable. La dernière couche (classifieur) a été adaptée pour générer 10 vecteurs de sortie correspondant à nos 10 classes animales.

2.6.1 Mécanique interne de ResNet-18

L'architecture *Residual Network* (ResNet) a révolutionné l'apprentissage profond en introduisant les **connexions résiduelles** (*skip connections*). Dans un réseau convolutionnel classique profond, le signal du gradient a tendance à s'estomper lors de la phase de rétropropagation (le problème de la disparition du gradient). ResNet contourne ce problème en ajoutant l'entrée d'une couche directement à sa sortie mathématique ($F(x) + x$).

Dans le contexte de données Basse Fidélité (flou et bruit gaussien), cette architecture est cruciale : si une couche convolutionnelle n'arrive pas à extraire d'information pertinente à cause du bruit, la connexion résiduelle permet à l'information globale de l'image de continuer à circuler librement à travers le réseau sans être détruite. La version à 18 couches (ResNet-18) offre le compromis parfait entre expressivité et prévention du sur-apprentissage (*overfitting*) sur notre corpus de ≈25 000 images.

2.6.2 Justification des hyperparamètres et de la fonction de coût

Pour garantir la reproductibilité et la comparabilité des *Baselines*, une configuration stricte d'hyperparamètres a été codée en dur dans notre script d'entraînement (`train_baselines.py`) :

— **Fonction de perte (Loss) –** `CrossEntropyLoss` : Il s'agit du standard mathématique pour les problèmes de classification multi-classes. Cette fonction combine une activation Softmax (pour transformer les sorties brutes du modèle en probabilités de 0 à 1) et une perte log-vraisemblance

négative (NLL). Elle pénalise fortement le modèle s'il est très confiant sur une mauvaise prédiction, ce qui est idéal pour forcer le réseau à douter sur des images floues.

— **Optimiseur – `Adam`** : Contrairement à une descente de gradient stochastique classique (SGD), Adam adapte dynamiquement le taux d'apprentissage pour chaque paramètre individuel en utilisant les moments du premier et second ordre des gradients. Cela permet une convergence beaucoup plus rapide et stable, particulièrement utile lors d'un entraînement *from scratch*.

— **Taux d'apprentissage (*Learning Rate*)** : Fixé à $lr = 0.001$. C'est la valeur par défaut recommandée pour l'optimiseur Adam, offrant un pas de descente suffisamment grand pour échapper aux minima locaux lors des premières époques, tout en évitant la divergence.

— **Taille de lot (*Batch Size*)** : Fixée à 64. Cette valeur permet d'optimiser l'utilisation de la mémoire vidéo (VRAM) du GPU T4, tout en garantissant un gradient stochastique suffisamment lissé pour ne pas rendre l'apprentissage chaotique face au bruit des images BF.

— **Nombre d'époques** : Fixé à 20. Des tests préliminaires ont montré qu'au-delà de 20 époques, la courbe d'apprentissage sur le jeu d'entraînement atteint un plateau asymptotique, et le risque de mémorisation du bruit (*overfitting*) augmente considérablement.

2.6.3 Prétraitement et optimisations matérielles

Afin d'exploiter pleinement l'architecture hybride (VS Code / Google Colab), deux optimisations logicielles majeures ont été intégrées à l'implémentation :

1. **Normalisation des tenseurs** : Avant d'entrer dans le réseau, toutes les images (redimensionnées en 224×224 pixels) subissent une normalisation spatiale basée sur les statistiques du jeu de données ImageNet (Moyennes : `[0.485, 0.456, 0.406]`, Écarts-types : `[0.229, 0.224, 0.225]`). Cette opération centre les données autour de zéro, accélérant la convergence de la descente de gradient.

2. **Précision Mixte Automatique (AMP)** : L'entraînement utilise les modules `torch.amp.autocast` et `GradScaler`. Cette technique exécute certaines opérations mathématiques en virgule flottante 16 bits (FP16) au lieu de 32 bits (FP32). Cela a permis de réduire drastiquement la consommation mémoire et d'accélérer le temps de calcul sur les Tensor Cores du GPU NVIDIA T4, réduisant la durée d'une époque de plusieurs minutes à une quarantaine de secondes, sans aucune perte de précision prédictive.

CHAPITRE 3

Construction des Modèles de Référence

Avant d'explorer des stratégies d'optimisation complexes, il est indispensable d'établir des **bornes de performances** (supérieure et inférieure) via des *baselines*.

3.1 Stratégie d'évaluation croisée face au décalage de domaine

Un modèle entraîné sur des images floues (domaine BF) peut ne pas généraliser correctement sur des images nettes (domaine HF) — c'est le **Domain Shift**. Pour quantifier ce phénomène, chaque modèle est évalué selon **trois passages distincts** :

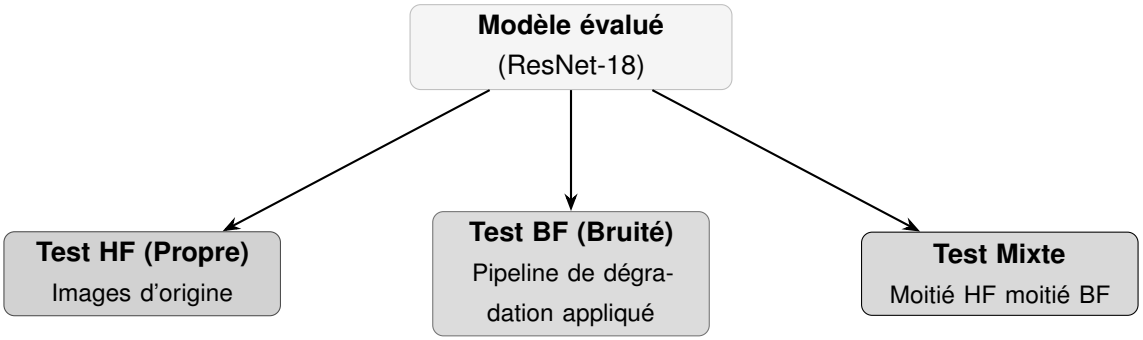

3.2 Définition des modèles de référence

#	Modèle	Images	Coût	Hypothèse de comportement
1	**Premium** (Train HF uniquement)	≈2 500 HF	25 000 CA	Excellentes performances sur Test HF. Effondrement prévu sur Test BF (aucune robustesse au bruit).
2	**Low-Cost** (Train BF uniquement)	≈22 700 BF	22 700 CA	Très performant sur Test BF. Généralisation sur Test HF dépendra de la capacité à extrapoler des contours nets depuis des signaux flous.
3	**Naïf Mixte** (Borne supérieure)	≈25 200 HF+BF	47 700 CA	Meilleures performances globales (Test Mixte). Sert de borne supérieure absolue. **L'objectif des phases suivantes est d'atteindre ce niveau à coût réduit.**

3.3 Stratégie d'implémentation logicielle

Afin d'éliminer tout biais d'implémentation, le code a été factorisé en un **unique script d'entraînement paramétrable**. Ce script accepte un argument de mode (`HF`, `BF`, ou `MIXTE`), charge dynamiquement le sous-ensemble correspondant, procède à l'entraînement et exécute automatiquement la séquence des trois tests d'évaluation croisée.

3.4 Analyse des résultats

Les trois modèles de référence ont été entraînés avec succès sur 20 époques. Les résultats obtenus, résumés dans le tableau ci-dessous, mettent en évidence la dynamique du compromis coût/performance.

Modèle Entraîné	Coût Total (CA)	Test HF	Test BF	Test Mixte	Temps d'entraînement
BL 1 (HF)	470 400	56,20 %	35,16 %	45,68 %	2,84 min
BL 2 (BF)	424 260	59,07 %	63,66 %	61,36 %	27,05 min
BL 3 (Mixte)	894 660	75,90 %	65,03 %	70,47 %	29,78 min

L'analyse de ces métriques permet de tirer trois conclusions majeures concernant le comportement du réseau ResNet-18 face à nos données :

— **L'effondrement face au bruit (*Domain Shift*) :** La Baseline 1, entraînée exclusivement sur des données parfaites, obtient un score de 56,20 % sur le test HF. Cependant, confrontée au domaine BF (flou et bruit gaussien), sa précision s'effondre à 35,16 %. Ce résultat prouve l'incapacité d'un modèle "Premium" classique à généraliser face à des perturbations non rencontrées lors de l'apprentissage.

— **Le paradoxe de la quantité :** La Baseline 2 possède un budget inférieur à la Baseline 1 (424 260 CA contre 470 400 CA) mais la surpasse systématiquement, **y compris sur les images nettes** (59,07 %). Cela démontre qu'en apprentissage profond, l'immense diversité contenue dans $\approx$22 700 images floues prime sur la perfection visuelle de seulement $\approx$2 500 images.

— **La validation de la borne supérieure :** La Baseline 3 confirme son statut théorique. En ayant appris simultanément sur le volume massif (BF) et sur les détails discriminants (HF), elle atteint une précision de 75,9 % sur le test de haute fidélité. Toutefois, son coût d'acquisition est beaucoup plus élevé que les autres baseline.

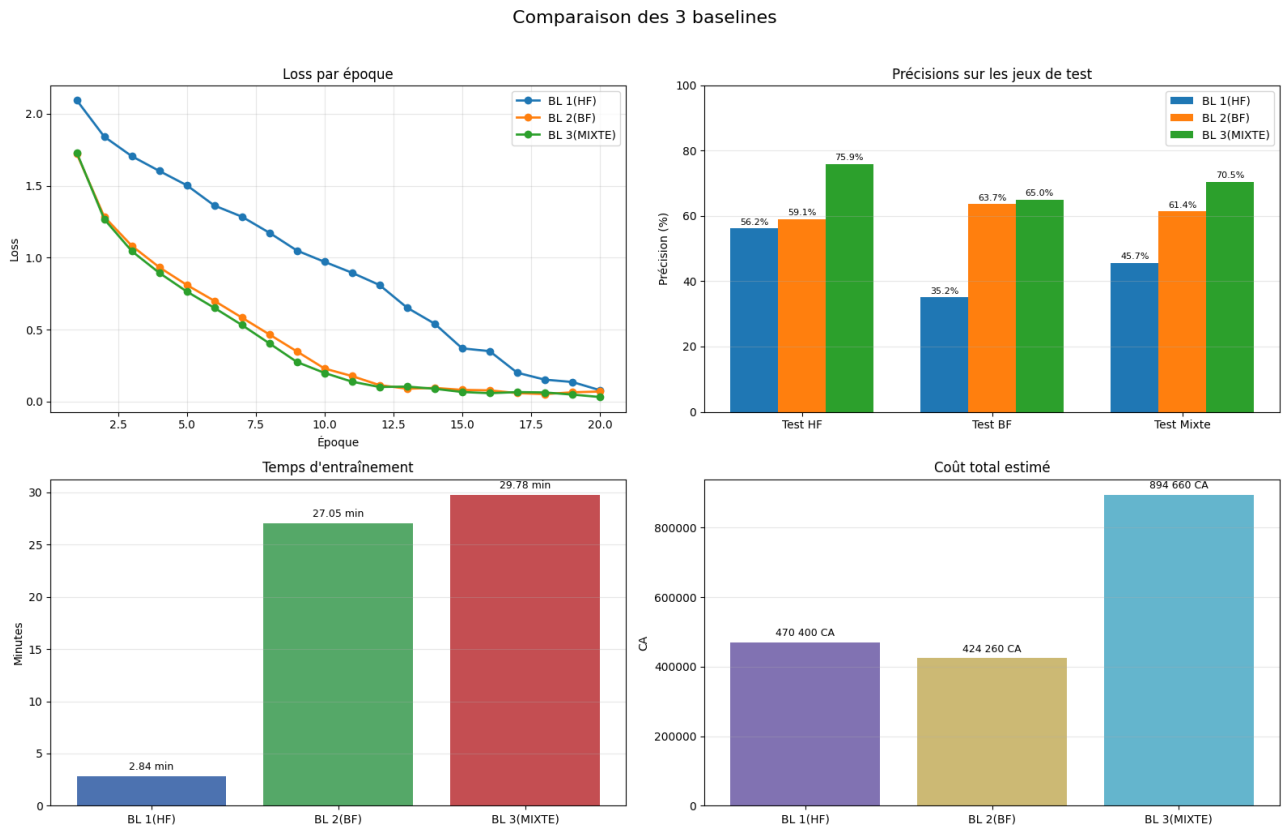

FIGURE 3.1 – Comparaison visuelle des trois baselines (BL 1(HF), BL 2(BF), BL 3(MIXTE)) : loss par époque, précisions de test, temps d'entraînement et coût total estimé.

Bibliographie

[1] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun. *Deep Residual Learning for Image Recognition*. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016.

[2] Diederik P. Kingma, Jimmy Ba. *Adam : A Method for Stochastic Optimization*. International Conference on Learning Representations (ICLR), 2015.

[3] Ian Goodfellow, Yoshua Bengio, Aaron Courville. *Deep Learning*. MIT Press, 2016. Disponible en ligne : `https://www.deeplearningbook.org`

[4] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, Alexander C. Berg, Li Fei-Fei. *ImageNet Large Scale Visual Recognition Challenge*. International Journal of Computer Vision (IJCV), 123(3) :211–252, 2015.

[5] Dan Hendrycks, Thomas Dietterich. *Benchmarking Neural Network Robustness to Common Corruptions and Perturbations*. International Conference on Learning Representations (ICLR), 2019.

[6] Marc Peter Deisenroth, Jun Wei Ng. *Distributed Gaussian Processes*. International Conference on Machine Learning (ICML), 2015.

[7] Marc C. Kennedy, Anthony O'Hagan. *Predicting the Output from a Complex Computer Code When Fast Approximations Are Available*. Biometrika, 87(1) :1–13, 2000.

[8] Mengye Ren, Wenyuan Zeng, Bin Yang, Raquel Urtasun. *Learning to Reweight Examples for Robust Deep Learning*. International Conference on Machine Learning (ICML), 2018.

[9] Bo Han, Quanming Yao, Xingrui Yu, Gang Niu, Miao Xu, Weihua Hu, Ivor Tsang, Masashi Sugiyama. *Co-teaching : Robust Training of Deep Neural Networks with Extremely Noisy Labels*. Advances in Neural Information Processing Systems (NeurIPS), 2018.

[10] Qizhe Xie, Minh-Thang Luong, Eduard Hovy, Quoc V. Le. *Self-training with Noisy Student improves ImageNet classification*. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020.