**UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD**

Projet PF22

**RAPPORT DE PROJET**

# Réduction des Coûts d'Apprentissage par Approche Multi-Fidélité

Ce projet explore la possibilité de réduire drastiquement les coûts de constitution d'un jeu de données en combinant une faible proportion d'images **Haute Fidélité** avec une grande majorité d'images **Basse Fidélité** acquises à moindre coût.

---

**Auteur :** Ivann Vasic
**Période :** Mars – Juin 2026
**Cadre :** Projet PF22 — UTBM

# Résumé

L'entraînement de modèles d'apprentissage profond performants nécessite traditionnellement de vastes ensembles de données de haute qualité, dont l'acquisition et l'annotation s'avèrent souvent coûteuses en temps et en ressources. Ce projet explore une approche alternative : **l'apprentissage multi-fidélité**.

L'objectif est de démontrer qu'il est possible de réduire drastiquement les coûts de constitution d'un jeu de données en combinant une faible proportion d'images de **Haute Fidélité (HF)** avec une grande majorité d'images dégradées acquises à moindre coût (**Basse Fidélité - BF**).

**Mots-clés :** Apprentissage profond · Multi-fidélité · CNN · ResNet-18 · Dégradation d'image · Optimisation des coûts · Domain Shift · Animals-10

# Table des matières

**1 Préparation et Fondation** **4**

1.1 Environnement de travail et architecture hybride . . . . . 4

1.2 Sélection du jeu de données . . . . . 4

**2 Construction de l'Environnement Multi-Fidélité** **6**

2.1 Découpage et répartition des données . . . . . 6

2.2 Pipeline de dégradation de la qualité . . . . . 6

2.3 Définition de la métrique de coût . . . . . 7

**3 Construction des Modèles de Référence** **8**

3.1 Stratégie d'évaluation croisée face au décalage de domaine . . . . . 8

3.2 Sélection et justification de l'architecture neuronale . . . . . 8

3.3 Définition des modèles de référence . . . . . 9

3.4 Stratégie d'implémentation logicielle . . . . . 9

3.5 Analyse des résultats . . . . . 9

CHAPITRE 1

# Préparation et Fondation

Les choix et la mise en place de l'environnement de travail ont été guidés par des contraintes matérielles et par la nécessité de disposer de données adaptées à la simulation d'une approche multi-fidélité.

## 1.1 Environnement de travail et architecture hybride

Une **architecture hybride déportée** a été conçue, alliant faible coût et haute efficacité, en cohérence directe avec la thématique du projet.

| Outil | Rôle | Détail |
|---|---|---|
| **VS Code** | IDE local | Écriture du code, gestion des terminaux et suivi de projet |
| **Google Colab** | Calcul distant | GPU NVIDIA T4 cloud, connecté directement à VS Code via extension sécurisée |
| **Google Drive** | Stockage persistant | Monté à chaque session ; héberge le dataset et sauvegarde les *checkpoints* par époque |
| **GitHub** | Versioning | Contrôle de version et sauvegarde du code source expérimental |

Un script de test d'intégration a été développé pour valider cette synergie. Il a mis en évidence un **goulot d'étranglement réseau (I/O Bottleneck)** lors de la lecture de milliers de fichiers via le protocole FUSE de Drive, résolu par l'extraction locale d'archives ZIP directement sur le SSD de l'instance Colab.

## 1.2 Sélection du jeu de données

Le jeu de données doit être suffisamment difficile pour que la dégradation visuelle impacte mesurément les performances du réseau. Quatre candidats ont été évalués :

| Dataset | Images | Avantages | Inconvénients |
|---|---|---|---|
| Imagenette | 13 000 | Standard académique, itérations rapides | Trop « facile » pour ResNet-18 ($\approx$95% sans dégradation) |
| STL-10 | 105 000 | Grand jeu non étiqueté (100k images) | Résolution native 96$\times$96 trop faible |
| Oxford Pets | 7 400 | Classification fine-grained, très sensible aux dégradations | Volume insuffisant, nécessite un pré-entraînement lourd |
| **Animals-10** | **26 179** | **Haute résolution, volume idéal, proche des conditions réelles** | Bruit de labels et filigranes (peuvent être corrigés) |

**Choix retenu : Animals-10**

Son volume (26 179 images après nettoyage) permet un entraînement *from scratch* stable avec ResNet-18. Sa haute résolution native offre une large plage dynamique pour le pipeline de dégradation. Son caractère communautaire le rapproche des conditions industrielles réelles.

CHAPITRE 2

# Construction de l'Environnement Multi-Fidélité

Afin d'étudier l'impact de la qualité des données sur les performances d'apprentissage, un environnement expérimental a été construit : découpage asymétrique du dataset, pipeline de dégradation et métrique de coût.

## 2.1 Découpage et répartition des données

Le schéma ci-dessous illustre le découpage du jeu Animals-10.

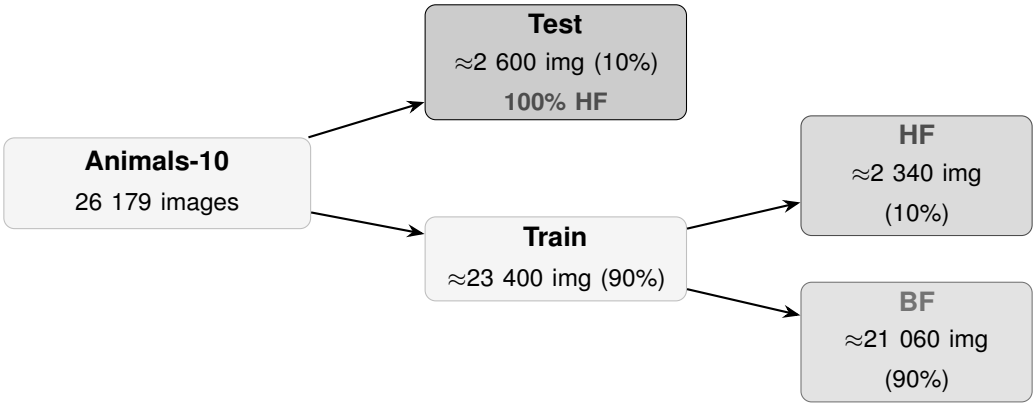


**Principe clé**

Le jeu de **test est exclusivement HF** pour toutes les expériences : l'évaluation doit mesurer la capacité de généralisation sur des données de haute qualité, quel que soit le domaine utilisé à l'entraînement.

## 2.2 Pipeline de dégradation de la qualité

La génération des images Basse Fidélité applique deux transformations consécutives **à la volée** :

| # | Transformation | Description | Effet simulé |
|---|---|---|---|
| **1** | Sous-échantillonnage (*Downsampling*) | Réduction à 64×64 px puis redimensionnement à 224×224 px par interpolation bilinéaire | Perte d'information : image floue et pixélisée |
| **2** | Bruit Gaussien | Ajout d'un bruit aléatoire (grain) aux tenseurs de l'image | Simulation du bruit ISO des capteurs électroniques |

## 2.3 Définition de la métrique de coût

| Type d'image | Coût | Justification |
|---|---|---|
| Haute Fidélité ($C_{HF}$) | **10 CA** | Expert humain ou équipement onéreux |
| Basse Fidélité ($C_{BF}$) | **1 CA** | Collecte automatisée, pré-étiquetage web |

**Pourquoi pas le temps de calcul ?**

Le temps de calcul brut ($Temps_{Epoch} \times Nombre_{Epochs}$) a été écarté en raison de l'instabilité des environnements cloud (fluctuations de charge serveur, allocation dynamique GPU, goulots I/O). Le **Crédit d'Annotation** offre un référentiel **invariant, agnostique au matériel**, centré sur la valeur intrinsèque de la donnée.

CHAPITRE 3

# Construction des Modèles de Référence

Avant d'explorer des stratégies d'optimisation complexes, il est indispensable d'établir des **bornes de performances** (supérieure et inférieure) via des *baselines*.

## 3.1 Stratégie d'évaluation croisée face au décalage de domaine

Un modèle entraîné sur des images floues (domaine BF) peut ne pas généraliser correctement sur des images nettes (domaine HF) — c'est le **Domain Shift**. Pour quantifier ce phénomène, chaque modèle est évalué selon **trois passages distincts** :

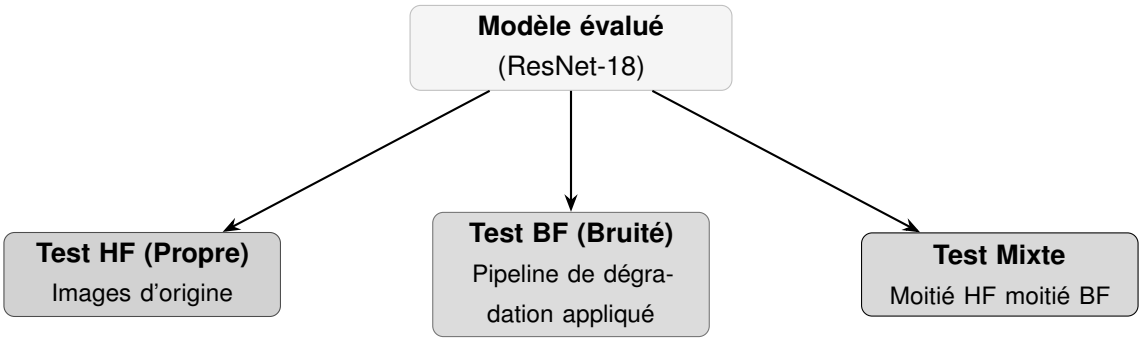


## 3.2 Sélection et justification de l'architecture neuronale

| Architecture | Paramètres | Points forts | Limites / Pertinence |
|---|---|---|---|
| **ResNet-18** ✓ | ≈11 M | Standard académique, connexions résiduelles, robuste au bruit | **Pertinence excellente** — compromis idéal |
| MobileNetV2 | ≈3,4 M | Ultra-léger, économe en VRAM, itérations rapides | S'effondre sur données fortement bruitées |
| EfficientNet-B0 | ≈5,3 M | Ratio précision/paramètres optimisé mathématiquement | Difficile à faire converger *from scratch* |
| ViT-Tiny | ≈5 M | Architecture Transformer, vision globale | Sur-apprend massivement sans pré-entraînement |

**Architecture retenue : ResNet-18**

Ses ≈11M paramètres permettent l'extraction de caractéristiques à travers le bruit. Ses connexions résiduelles garantissent un entraînement stable. Les hyperparamètres (Optimiseur Adam, taux d'apprentissage, taille de lot) resteront **strictement identiques** pour toutes les expériences.

## 3.3 Définition des modèles de référence

| # | Modèle | Images | Coût | Hypothèse de comportement |
|---|---|---|---|---|
| 1 | **Premium** (Train HF uniquement) | ≈2 500 HF | 25 000 CA | Excellentes performances sur Test HF. Effondrement prévu sur Test BF (aucune robustesse au bruit). |
| 2 | **Low-Cost** (Train BF uniquement) | ≈22 700 BF | 22 700 CA | Très performant sur Test BF. Généralisation sur Test HF dépendra de la capacité à extrapoler des contours nets depuis des signaux flous. |
| 3 | **Naïf Mixte** (Borne supérieure) | ≈25 200 HF+BF | 47 700 CA | Meilleures performances globales (Test Mixte). Sert de borne supérieure absolue. **L'objectif des phases suivantes est d'atteindre ce niveau à coût réduit.** |

## 3.4 Stratégie d'implémentation logicielle

Afin d'éliminer tout biais d'implémentation, le code a été factorisé en un **unique script d'entraînement paramétrable**. Ce script accepte un argument de mode (`HF`, `BF`, ou `MIXTE`), charge dynamiquement le sous-ensemble correspondant, procède à l'entraînement et exécute automatiquement la séquence des trois tests d'évaluation croisée.

## 3.5 Analyse des résultats

Les trois modèles de référence ont été entraînés avec succès sur 20 époques. Les résultats obtenus, résumés dans le tableau ci-dessous, mettent en évidence la dynamique du compromis coût/performance.

| Modèle Entraîné | Coût Total (CA) | Test HF | Test BF | Test Mixte | Temps d'entraînement |
|---|---|---|---|---|---|
| BL 1 (HF) | 470 400 | 56,20 % | 35,16 % | 45,68 % | 2,84 min |
| BL 2 (BF) | 424 260 | 59,07 % | 63,66 % | 61,36 % | 27,05 min |
| BL 3 (Mixte) | 894 660 | 75,90 % | 65,03 % | 70,47 % | 29,78 min |

L'analyse de ces métriques permet de tirer trois conclusions majeures concernant le comportement du réseau ResNet-18 face à nos données :

— **L'effondrement face au bruit (*Domain Shift*) :** La Baseline 1, entraînée exclusivement sur des données parfaites, obtient un score de 56,20 % sur le test HF. Cependant, confrontée au domaine BF (flou et bruit gaussien), sa précision s'effondre à 35,16 %. Ce résultat prouve l'incapacité d'un modèle "Premium" classique à généraliser face à des perturbations non rencontrées lors de l'apprentissage.

— **Le paradoxe de la quantité :** La Baseline 2 possède un budget inférieur à la Baseline 1 (424 260 CA contre 470 400 CA) mais la surpasse systématiquement, **y compris sur les images nettes** (59,07 %). Cela démontre qu'en apprentissage profond, l'immense diversité contenue dans ≈22 700 images floues prime sur la perfection visuelle de seulement ≈2 500 images.

— **La validation de la borne supérieure :** La Baseline 3 confirme son statut théorique. En ayant appris simultanément sur le volume massif (BF) et sur les détails discriminants (HF), elle atteint une précision de 75,9 % sur le test de haute fidélité. Toutefois, son coût d'acquisition est beaucoup plus élevé que les autres baseline.

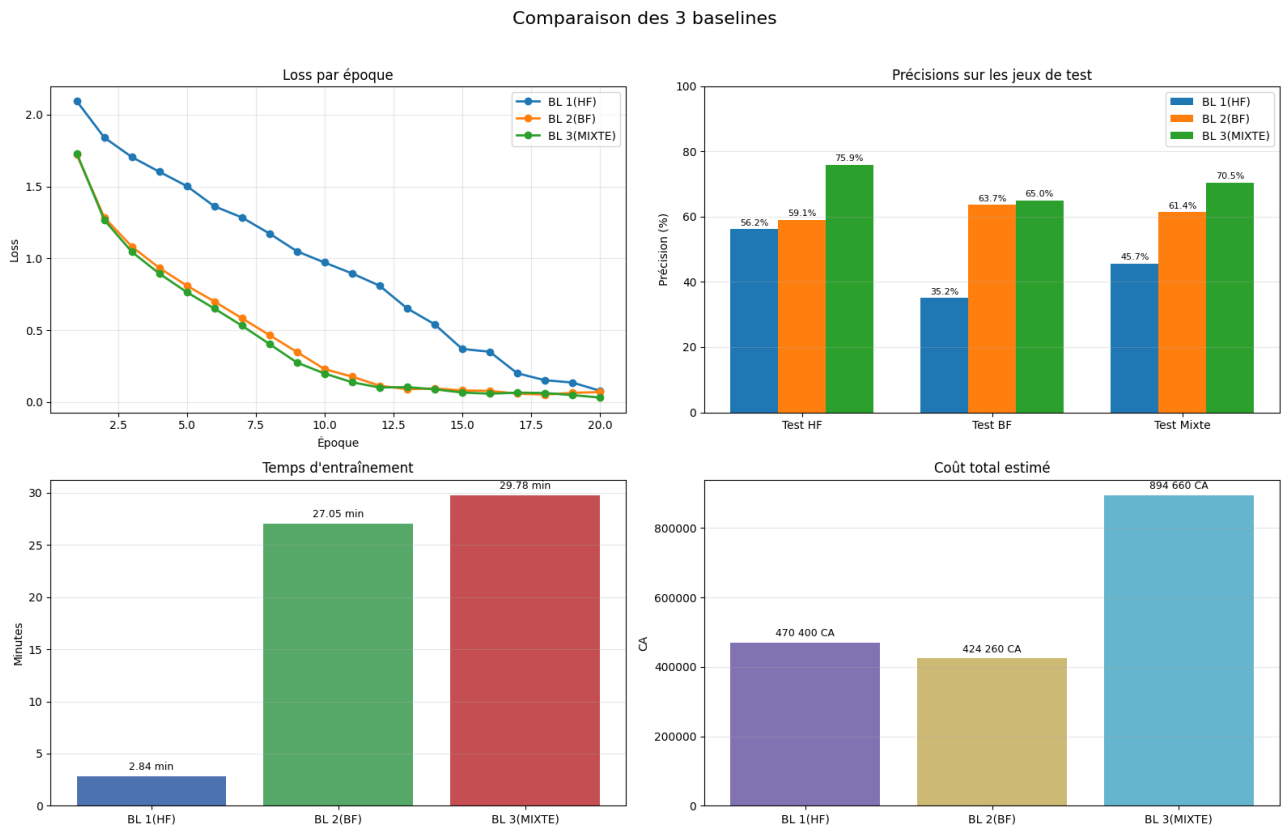


FIGURE 3.1 – Comparaison visuelle des trois baselines (BL 1(HF), BL 2(BF), BL 3(MIXTE)) : loss par époque, précisions de test, temps d'entraînement et coût total estimé.

# Bibliographie


[1] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun. *Deep Residual Learning for Image Recognition*. Proceedings of the IEEE conference on computer vision and pattern recognition (CVPR), 2016.

[2] Mengye Ren, Wenyuan Zeng, Bin Yang, Raquel Urtasun. *Learning to Reweight Examples for Robust Deep Learning*. International Conference on Machine Learning (ICML), 2018.

[3] Bo Han, Quanming Yao, Xingrui Yu, Gang Niu, Miao Xu, Weihua Hu, Ivor Tsang, Masashi Sugiyama. *Co-teaching : Robust Training of Deep Neural Networks with Extremely Noisy Labels*. Advances in Neural Information Processing Systems (NeurIPS), 2018.

[4] Qizhe Xie, Minh-Thang Luong, Eduard Hovy, Quoc V. Le. *Self-training with Noisy Student improves ImageNet classification*. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2020.