



UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

Module **PF22** — Apprentissage profond

Réduction des Coûts d'Apprentissage par Approche Multi-Fidélité

Le constat

- ▶ La performance d'un réseau dépend de la **quantité** et de la **qualité** des données.
- ▶ Données **Haute Fidélité** : haute résolution, experts, capteurs chers → **rare et coûteuses**.
- ▶ Données **Basse Fidélité** : dégradées, web, capteurs bas de gamme → **abondantes et bon marché**.

L'idée : l'apprentissage multi-fidélité


- ▶ Mélanger un *petit* volume HF avec un *grand* volume BF.

Problématique. Comment exploiter beaucoup de données BF bon marché pour **maximiser la précision sur le domaine HF**, tout en **minimisant le coût d'acquisition** ?

Objectif explicitement orienté HF

le BF n'est qu'un levier économique

Concrètement : Haute Fidélité vs Basse Fidélité



Dégradation BF canonique

Sous-échantillonnage

224 → 64 px

+ bruit gaussien $\sigma = 0,15$

+ compression **JPEG** q60

Appliquée à la volée et
déterministe par image (train BF =
test BF, pas de décalage parasite).

3 datasets de natures différentes (animaux, races fine-grained, scènes) pour valider la généralité.

Découpage des données

- ▶ Test **10 %** (100 % HF) ; Train **90 %**.
- ▶ Train découpé en **10 % HF + 90 % BF**.

Évaluation croisée

- ▶ 3 jeux de test : **HF, BF, Mixte**.
- ▶ Critère prioritaire : **Test HF**.

Rigueur & reproductibilité

- ▶ Modèle : **ResNet-18 *from scratch*** (AMP FP16).
- ▶ **3 datasets × 3 graines** → moyenne $\pm$ écart-type.
- ▶ Dégradation centralisée & déterministe.
- ▶ Calcul sur **serveur GPU V100S**.

Tout résultat est reporté en **moyenne $\pm$ écart-type** sur 3 graines → conclusions robustes au hasard d'initialisation.

Trois métriques distinctes

- ▶ **Coût donnée** — acquisition, payé *une fois*.
- ▶ **Coût calcul** — images vues à l'entraînement.
- ▶ **Coût total** — calcul pondéré par le coût donnée.

Coût unitaire $\propto$ résolution

$$C(d) = C_{\min} + (C_{\text{HF}} - C_{\min}) \left(\frac{d}{224} \right)^2$$

Calibration : **HF = 10**, **BF (64 px) = 1** $\Rightarrow$ ratio de coût **10 : 1**.

Exemple — Animals-10

Pool d'entraînement :
2 352 HF + 21 213 BF

$$\underbrace{2\,352 \times 10}_{\text{HF}} + \underbrace{21\,213 \times 1}_{\text{BF}} = \mathbf{44\,733\ CA}$$

C'est le **coût donnée** commun à toute méthode utilisant le pool complet.

Les méthodes se départagent alors sur le **coût total** (passages sur le HF coûteux).

Modèles de référence (les bornes)

Baseline (Animals-10)	Test HF	Test BF	Coût donnée
BL 1 — Premium (HF seul)	54,3 $\pm$ 2,2	27,8 $\pm$ 0,8	23 520
BL 2 — Low-Cost (BF seul)	61,3 $\pm$ 6,3	71,0 $\pm$ 1,5	21 213
BL 3 — Mixte (borne haute)	74,0 $\pm$ 3,0	72,9 $\pm$ 1,1	44 733

Effondrement face au bruit

BL 1 (HF seul) : **54,3 %** $\rightarrow$ **27,8 %** sur BF. Le *domain shift* est réel et brutal.

Paradoxe de la quantité

BL 2 (BF seul) bat BL 1 **même sur HF** (61,3 vs 54,3 %) pour un coût *inférieur*.

BL 3 (Mixte) = borne supérieure à atteindre... mais coûteuse. **Objectif : l'égaliser à moindre coût.**

Quatre stratégies multi-fidélité (objectif HF)

S1 · Transfer Learning séquentiel

Pré-entraînement sur le volume **BF**, puis **fine-tuning** sur le sous-ensemble **HF**. ($BF \rightarrow HF$)

S2 · Co-training pondéré

HF et BF dans **chaque batch**, avec une **pondération** de la perte favorisant le HF.

S3 · Curriculum Learning


Un seul entraînement où la **proportion de HF augmente par paliers** ($0\% \rightarrow 100\%$).
Transition douce.

S4 · EWC (Elastic Weight Consolidation)

Transfert séquentiel + **pénalité de Fisher** protégeant les poids importants pour le BF (anti-oubli).

Chaque stratégie est aussi déclinée en version **optimisée par Optuna**.

Résultats — précision HF par modèle




Toutes les stratégies orientées HF **dépassent les baselines**, sur les **3 datasets**.

En tête : EWC et Transfer Learning

(Animals : EWC 78,0 / S1 77,7 / Curriculum 76,5 / CoTrain 63,8%)

Légende des figures : « S5 » = EWC = Stratégie 4 ; « S3 » = Curriculum = Stratégie 3.

Résultats — le compromis coût / performance



Les stratégies forment la **frontière efficiente** : aucune baseline ne les domine en précision *et* en coût.

Résultat clé : on **dépasse** la borne haute (BL3) sur HF **tout en divisant le coût total par ≈ 2**

(Animals : 400 230 vs 894 660 CA, à coût donnée identique).

Méthode

- ▶ Recherche bayésienne (TPE), **20 essais** par stratégie × dataset.
- ▶ Objectif : précision de validation HF.

Ce qu'on apprend

- ▶ Gros gains sur les stratégies **instables** : Co-training **+9,4 pts** (Animals), Curriculum **+5,3 pts** (Imagewoof).

Limite observée

Peu — voire pas — de gain sur les stratégies **déjà fortes et stables** (S1, EWC) : EWC se dégrade même (λ trop relâché), signe d'un léger sur-ajustement à la validation (budget de 20 essais).

Piste : optimisation **multi-objectif** (précision *et* coût) avec plus d'essais.

Robustesse & sensibilité au coût

Robustesse à la dégradation

Test sur données *encore plus* dégradées :

- ▶ Arbitrage **précision-propre vs robustesse**.
- ▶ EWC / S1 : meilleurs sur données propres.
- ▶ **Curriculum** : le **plus robuste** sous forte dégradation.

Sensibilité au ratio de coût HF :BF

En faisant varier le ratio ($2 \rightarrow 50$) :

- ▶ Le classement *d'efficience* **n'est pas robuste** (BL 1 si HF bon marché, BL 2 si HF cher).
- ▶ Mais la **dominance en précision HF absolue** des stratégies, elle, l'est.

La supériorité des stratégies multi-fidélité en **précision HF** est confirmée sous **multi-graines, 3 datasets** et ces analyses transversales.

EWC $\gtrsim$ Transfer Learning > Curriculum > Co-training $\ggg$ baselines

À retenir

- ▶ Objectif **atteint** : on dépasse le mélange naïf coûteux **à moitié prix**.
- ▶ *Domain shift* et *paradoxe de la quantité* confirmés.
- ▶ Résultats **cohérents** sur 3 datasets, multi-graines.

Limites & perspectives

- ▶ ResNet-18 *from scratch*, dégradation unique, 20 époques / 20 essais.
- ▶ Backbones **pré-entraînés** (ImageNet).
- ▶ **Hybrider** EWC + curriculum.
- ▶ Optuna **multi-objectif**.

Des données bon marché et imparfaites : non pas un pis-aller, mais un véritable levier.



Merci de votre attention

Questions & discussion
