UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD
Projet PF22

Réduction des Coûts d'Apprentissage

par Approche Multi-Fidélité

Exploration de la combinaison de données Haute et Basse Fidélité pour réduire le coût d'acquisition des jeux de données en deep learning.

Ivann Vasic

Mars – Juin 2026 | Présentation de mi-parcours

Plan de la présentation

1. Contexte et objectifs
2. Environnement de travail
3. Jeu de données & pipeline
4. Architecture ResNet-18
5. Baselines (modèles de référence)
6. Stratégie 1 : Transfer Learning
7. Stratégie 2 : Co-training pondéré
8. Stratégie 3 : Noisy Student
9. Bilan et perspectives

Contexte et problématique

Le coût de la donnée : verrou économique principal

L'entraînement de réseaux profonds performants nécessite de vastes jeux de données **annotés de haute qualité**. Or :

- Photographe professionnel, équipement haute résolution ⇒ coût élevé
- Annotation manuelle par experts ⇒ temps long
- Passage à l'échelle industriel difficile

Question centrale

Peut-on remplacer la majorité des images coûteuses (**HF**) par des images dégradées bon marché (**BF**) sans sacrifier les performances ?

Haute Fidélité (HF)
Photo nette, résolution native
Coût : 10 CA / image

↓ **×10**

Basse Fidélité (BF)
Floue, bruitée, sous-échantillonnée
Coût : 1 CA / image

Approche Multi-Fidélité
10% HF + 90% BF

Environnement de travail

Architecture hybride déportée

Outil	Rôle
VS Code	IDE local, gestion terminaux
Google Colab	GPU NVIDIA T4 cloud
Google Drive	Stockage persistant datasets
GitHub	Versioning du code source

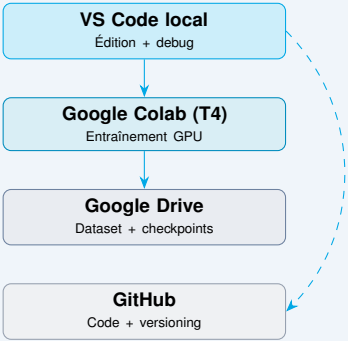

Optimisation clé : Précision Mixte (AMP)

Réduction époque : **plusieurs min** $\rightarrow$ $\approx$**40 sec**

`torch.amp.autocast` + `GradScaler` (FP16)

I/O Bottleneck résolu

Extraction ZIP locale sur SSD Colab au lieu de lecture FUSE Drive

Jeu de données : Animals-10

Sélection parmi 4 candidats

Dataset	Images	Verdict
Imagenette	13k	Trop facile (≈95%)
STL-10	105k	Résolution 96px trop faible
Oxford Pets	7.4k	Volume insuffisant
Animals-10	**26k**	**Retenu ✓**

Pourquoi Animals-10 ?

- Haute résolution native ⇒ large plage de dégradation
- Volume idéal pour entraînement *from scratch*
- Proche des conditions industrielles réelles

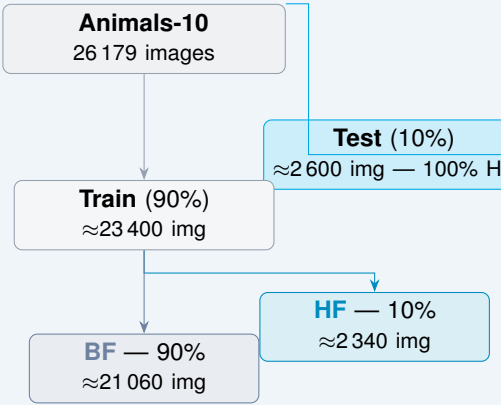

Pipeline de dégradation & Métrique de coût

Génération des images Basse Fidélité (à la volée)

Image HF
224×224

↓

Étape 1
Sous-échantillonnage
→ 64px → 224px

↓

Étape 2
Bruit Gaussien
(grain capteur)

Effets simulés :

- Flou + pixélisation (interpolation bilinéaire)
- Bruit ISO des capteurs électroniques

Crédit d'Annotation (CA)

Métrique indépendante du matériel, centrée sur la valeur intrinsèque de la donnée.

Type	Coût	Raison
HF	**10 CA**	Expert / équipement
BF	**1 CA**	Collecte auto.

Principe

Le test est **exclusivement HF** pour toutes les expériences : on évalue toujours la généralisation sur données de haute qualité.

Architecture : ResNet-18 *from scratch*

Pourquoi ResNet-18 ?

- $\approx$11M paramètres : compromis expressivité / overfitting
- **Connexions résiduelles** ($F(x) + x$) : résistance au bruit
- Standard académique reproductible
- Poids **aléatoires** (`weights=None`) : mesure l'impact pur du dataset
- Tête adaptée : **10 classes Animals-10**

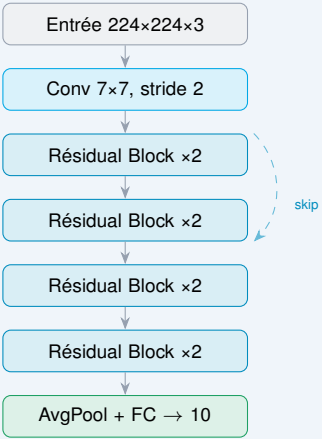

Hyperparamètres

Loss : **CrossEntropyLoss** Opt : **Adam** $lr = 0.001$
Batch : **64** Époques : **20** AMP : FP16

Modèles de référence (Baselines)

Bornes de performance inférieure et supérieure

Modèle	HF	BF	Mix.	Coût (CA)
BL 1 (HF)	56,20%	35,16%	45,68%	470k
BL 2 (BF)	59,07%	63,66%	61,36%	424k
BL 3 (Mixte)	**75,90%**	**65,03%**	**70,47%**	894k

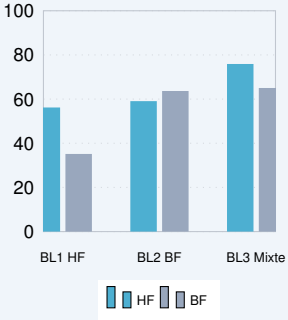

Trois enseignements clés :

Domain Shift

BL1 passe de 56% (HF) à 35% (BF) : effondrement face au bruit non vu.

Paradoxe quantité

BL2 surpasse BL1 **même sur HF** avec budget inférieur : 22k images floues $>$ 2.5k nettes.

Borne supérieure

BL3 fixe le plafond à 75,9% HF mais coûte 2× plus cher. **Objectif : l'atteindre à moindre coût.**

Stratégie 1 — Transfer Learning Séquentiel *BF → HF : pré-entraînement puis fine-tuning*

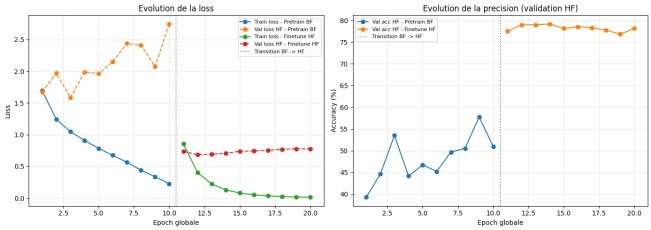

Loss et précision validation HF — Stratégie 1

Méthode	HF	BF	Mix	Coût
BL 2	59,07%	63,66%	61,36%	424k
BL 3	75,90%	65,03%	70,47%	894k
Strat. 1	**78,84%**	57,65%	68,25%	**400k**

Protocole en deux phases

- **Pré-entraînement BF** (10 époques, $lr = 0.001$)
- **Fine-tuning HF** (10 époques, $lr = 0.0003$)

Points forts : 78,84% HF (meilleur score), −55% de coût vs BL3.

Limite : Domain forgetting BF et léger overfitting en fin d'entraînement.

Stratégie 2 — Co-training par Batch avec Reweighting

HF et BF dans chaque batch avec pondération de la perte

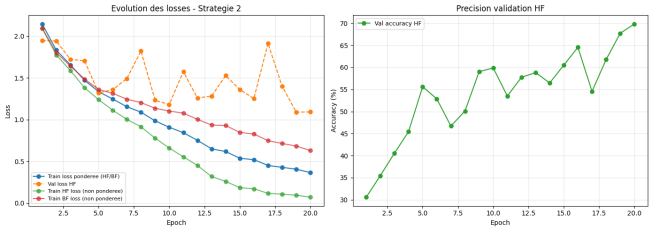

Losses et précision HF — Stratégie 2

Méthode	HF	BF	Mix	Coût
BL 2	59,07%	63,66%	61,36%	424k
Strat. 1	78,84%	57,65%	68,25%	400k
Strat. 2	**70,12%**	**61,90%**	**66,01%**	486k

Mécanisme dual

- Batch mixte : **16 HF + 48 BF** (25% HF)
- Pondération : $w_{HF} = 2.0$, $w_{BF} = 0.7$
- Entraînement conjoint sur 20 époques

Points forts : robustesse BF (61,90%) et gain de +13,9 pts HF vs BL1.
Limite : performance HF inférieure à la Stratégie 1 (70,12% vs 78,84%).

Stratégie 3 — Teacher-Student (Noisy Student adapté)

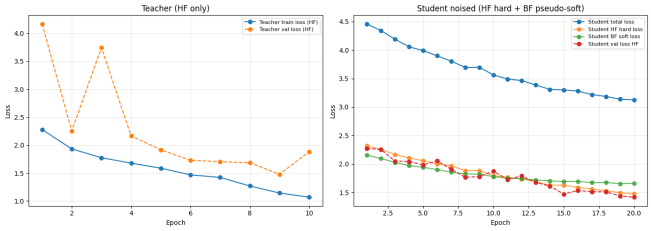

Pertes Teacher/Student — Stratégie 3

Méthode	HF	BF	Mix	Coût
BL 1	56,20%	35,16%	45,68%	470k
Strat. 1	**78,84%**	57,65%	68,25%	400k
Strat. 3	52,72%	28,46%	40,59%	988k

Schéma en trois étapes

- Teacher HF (10 époques), puis gel des poids
- Pseudo-labeling BF via probabilités Softmax
- Student noised : HF (hard) + BF (soft), $\alpha = 1.0$

Points forts : pipeline Teacher–Student complet et transférable à d'autres jeux de données.
Limite : Teacher faible ($\sim$43% val HF), pseudo-labels bruités et coût très élevé (988k) pour des performances faibles.

Bilan comparatif complet

Approche	HF	BF	Mix	Coût
BL 1 (HF)	56,20	35,16	45,68	470k
BL 2 (BF)	59,07	63,66	61,36	424k
BL 3 (Mixte)	75,90	65,03	70,47	894k
Strat. 1	**78,84**	57,65	68,25	**400k**
Strat. 2	70,12	**61,90**	66,01	486k
Strat. 3	52,72	28,46	40,59	988k

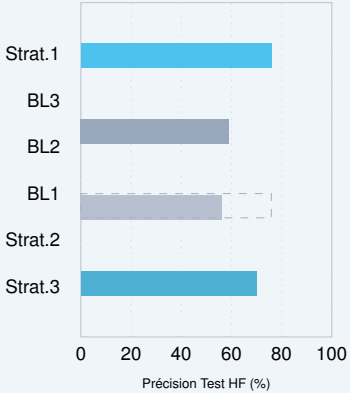

Résultat principal

Stratégie 1 dépasse BL3 sur HF
(**78,84% vs 75,90%**) à **55% du coût** (400k vs 894k CA).

Perspectives et prochaines étapes

Améliorations Stratégie 1 (priorité HF)

- Early stopping + checkpointing val HF
- Grille (E_{BF}, E_{HF}) pour optimiser durée relative
- Gel partiel du backbone en fine-tuning
- Augmentations ciblées (RandAugment, Mixup)

Améliorations Stratégie 3 (Noisy Student)

- Renforcer le Teacher (plus d'époques, meilleur LR)
- Seuil de confiance pseudo-labels (> 0.7)
- Réduire α BF (0.2–0.6), augmentations moins agressives
- Warm-up Student sur HF seul avant injection BF

Axes de recherche restants

- Frontière de Pareto coût/performance HF
- Variation du ratio HF/BF (5%, 15%, 20%...)
- Combinaison Stratégie 1 + curriculum pondéré
- Architecture backbone alternative (ResNet-34)

Objectif de fin de projet

Démontrer rigoureusement qu'une approche multi-fidélité permet d'atteindre ou dépasser les performances d'un modèle 100% HF à **coût d'annotation réduit d'au moins 50%**.

Merci pour votre attention

Conclusion

La **Stratégie 1 (Transfer Learning BF→HF)** valide la faisabilité de l'approche multi-fidélité : 78,84% sur Test HF, dépassant la borne supérieure, à 55% du coût. Le projet se poursuit vers l'optimisation et la robustesse inter-domaines.

78,84%
Test HF

−55% coût
vs BL3

3 stratégies
testées

6 modèles
comparés