UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD
PROJET PF22 • DÉPARTEMENT INFORMATIQUE

Réduction des Coûts d'Apprentissage

par Approche Multi-Fidélité

Exploration de la combinaison de données Haute et Basse Fidélité pour réduire le coût d'acquisition des jeux de données en deep learning.

Ivann Vasic
Étudiant Ingénieur — UTBM

Mars – Juin 2026 • Présentation de mi-parcours

SOMMAIRE

Plan de la présentation

01 Contexte et objectifs

02 Environnement de travail

03 Jeu de données & pipeline

04 Architecture ResNet-18

05 Baselines (modèles de référence)

06 Stratégie 1 : Transfer Learning

07 Stratégie 2 : Co-training pondéré

08 Stratégie 3 : Noisy Student

09 Bilan et perspectives

Contexte et problématique

Le coût de la donnée : un verrou économique

Un verrou économique majeur

L'entraînement de réseaux profonds performants nécessite de vastes jeux de données **annotés de haute qualité**. Or :

- Photographe professionnel, équipement haute résolution ⇒ coût élevé
- Annotation manuelle par experts ⇒ temps long
- Passage à l'échelle industriel difficile

Question centrale

Peut-on remplacer la majorité des images coûteuses (**HF**) par des images bon marché (**BF**) sans sacrifier les performances ?

Haute Fidélité
Photo nette, résolution native

×10

Basse Fidélité
Floue, bruitée, sous-échantillonnée

Approche Multi-Fidélité
10% HF + 90% BF

Environnement de travail

Architecture hybride déportée

Outil	Rôle
VS Code	IDE local, gestion terminaux
Google Colab	GPU NVIDIA T4 cloud
Google Drive	Stockage persistant datasets
GitHub	Versioning du code source

Optimisation clé : Précision Mixte (AMP)

Réduction époque : **plusieurs min** $\rightarrow$ $\approx$**40 sec**
`torch.amp.autocast` + `GradScaler` (FP16)

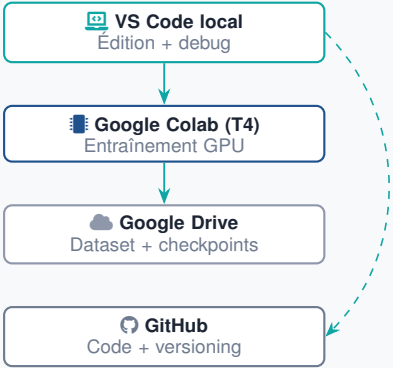

Jeu de données : Animals-10

Sélection parmi 4 candidats

Dataset	Images	Verdict
Imagenette	13k	Trop facile (≈95%)
STL-10	105k	Résolution 96px trop faible
Oxford Pets	7.4k	Volume insuffisant
Animals-10	**26k**	**Retenu ✓**

Pourquoi Animals-10 ?

- Haute résolution native ⇒ large plage de dégradation
- Volume idéal pour entraînement *from scratch*
- Proche des conditions industrielles réelles

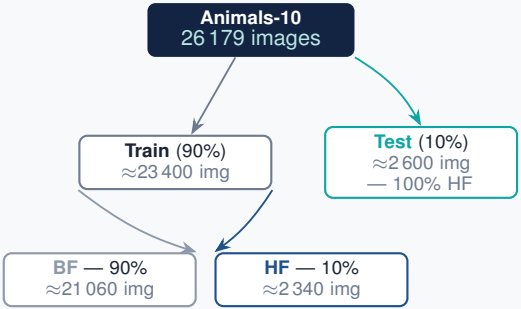

Pipeline de dégradation & Métrique de coût *Du HF vers le BF et comptabilisation du coût*

Génération des images BF (à la volée)

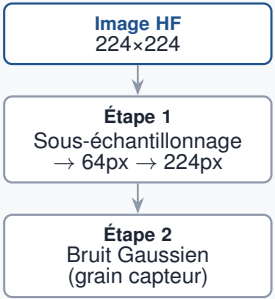

Effets simulés :

- Flou + pixélisation (interpolation bilinéaire)
- Bruit ISO des capteurs électroniques

Crédit d'Annotation (CA)

Métrique indépendante du matériel, centrée sur la valeur intrinsèque de la donnée.

Type	Coût	Raison
HF	**10 CA**	Expert / équipement
BF	**1 CA**	Collecte auto.

Principe

Le test est **exclusivement HF** pour toutes les expériences : on évalue toujours la généralisation sur données de haute qualité.

Architecture : ResNet-18 *from scratch*

Pourquoi ResNet-18 ?

- ≈11M paramètres : compromis expressivité / overfitting
- **Connexions résiduelles** ($F(x) + x$) : résistance au bruit
- Standard académique reproductible
- Poids **aléatoires** (`weights=None`) : mesure l'impact pur du dataset
- Tête adaptée : **10 classes Animals-10**

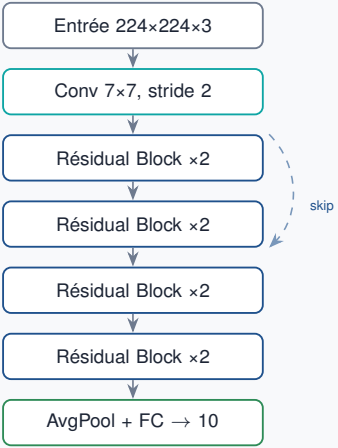

Hyperparamètres

Loss : **CrossEntropyLoss** Opt : **Adam** $lr = 0.001$
Batch : **64** Époques : **20** AMP : FP16

Modèles de référence (Baselines)

Bornes de performance inférieure et supérieure

Modèle	HF	BF	Mix.	Coût (CA)
BL 1 (HF)	56,20%	35,16%	45,68%	470k
BL 2 (BF)	59,07%	63,66%	61,36%	424k
BL 3 (Mixte)	**75,90%**	**65,03%**	**70,47%**	894k

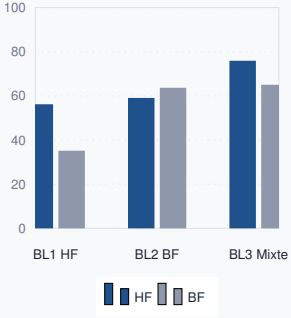

Trois enseignements clés :

Domain Shift

BL1 passe de 56% (HF) à 35% (BF) : effondrement face au bruit non vu.

Paradoxe quantité

BL2 surpasse BL1 **même sur HF** avec budget inférieur : 22k images floues $>$ 2.5k nettes.

Borne supérieure

BL3 fixe le plafond à 75,9% HF mais coûte 2× plus cher. **Objectif : l'atteindre à moindre coût.**

Stratégie 1 — Transfer Learning Séquentiel *BF → HF : pré-entraînement puis fine-tuning*

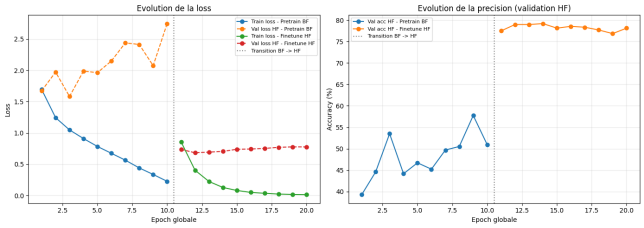

Loss et précision validation HF — Stratégie 1

Méthode	HF	BF	Mix	Coût
BL 2	59,07%	63,66%	61,36%	424k
BL 3	75,90%	65,03%	70,47%	894k
Strat. 1	**78,84%**	57,65%	68,25%	**400k**

Protocole en deux phases

- **Pré-entraînement BF** (10 époques, $lr = 0.001$)
- **Fine-tuning HF** (10 époques, $lr = 0.0003$)

Points forts : 78,84% HF (meilleur score), −55% de coût vs BL3.
Limite : Domain forgetting BF et léger overfitting en fin d'entraînement.

Stratégie 2 — Co-training par Batch avec Reweighting

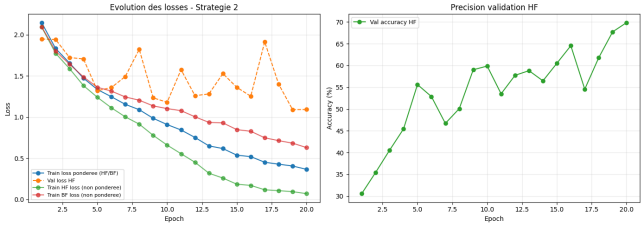

Losses et précision HF — Stratégie 2

Méthode	HF	BF	Mix	Coût
BL 3	75,90%	65,03%	70,47%	894k
Strat. 1	78,84%	57,65%	68,25%	400k
Strat. 2	**70,12%**	**61,90%**	**66,01%**	486k

Mécanisme dual

- Batch mixte : **16 HF + 48 BF** (25% HF)
- Pondération : $w_{HF} = 2.0$, $w_{BF} = 0.7$
- Entraînement conjoint sur 20 époques

Points forts : robustesse BF (61,90%) et gain de +13,9 pts HF vs BL1.
Limite : performance HF inférieure à la Stratégie 1 (70,12% vs 78,84%).

Bilan comparatif complet

Vue synoptique des 5 modèles

Approche	HF	BF	Mix	Coût
BL 1 (HF)	56,20	35,16	45,68	470k
BL 2 (BF)	59,07	63,66	61,36	424k
BL 3 (Mixte)	75,90	65,03	70,47	894k
Strat. 1	**78,84**	57,65	68,25	**400k**
Strat. 2	70,12	**61,90**	66,01	486k

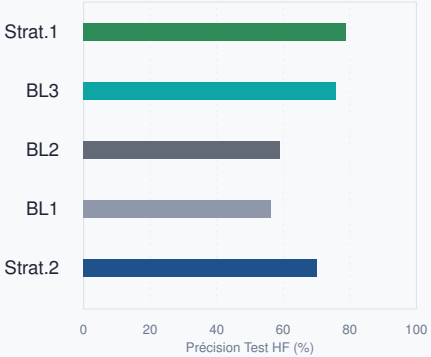

Résultat principal

Stratégie 1 dépasse BL3 sur HF
(**78,84% vs 75,90%**) à **55% du coût** (400k vs 894k CA).

Perspectives et prochaines étapes

Optimisations ciblées et axes de recherche

Améliorations Stratégie 1 (priorité HF)

- **Epochs BF/HF** : tester 5/15, 8/12, 12/8 pour ajuster robustesse BF vs spécialisation HF
- **Learning rate par phase** : LR fine-tuning ni trop haut (oubli), ni trop bas (sous-adaptation)
- **Split HF train/val** : comparer 70/30, 80/20, 85/15 pour stabiliser la sélection du meilleur modèle
- **Fonction de coût** : tester d'autres losses pour mieux gérer bruit et classes difficiles

Améliorations Stratégie 2 (Co-training pondéré)

- **Ratio batch HF/BF** : le 16/48 (25% HF) pilote directement le compromis HF/BF
- **Poids de loss** w_{HF}, w_{BF} : hyperparamètres centraux de la méthode
- **Fonction de loss alternative** : tester d'autres losses pour améliorer la généralisation
- **Planning dynamique** : partir d'un poids HF modéré, puis l'augmenter progressivement (curriculum)

Axes de recherche restants

- Tester d'autres stratégies avancées (Noisy Student, etc.)
- Faire varier tous les paramètres et améliorations possibles pour optimiser les stratégies
- Tester d'autres jeux de données
- Architecture backbone alternative (ResNet-34)
- Variation du ratio HF/BF (5%, 15%, 20%...)

Objectif de fin de projet

Démontrer rigoureusement qu'une approche multi-fidélité permet d'atteindre ou dépasser les performances d'un modèle 100% HF à **coût d'annotation réduit d'au moins 50%**.

CONCLUSION

Merci pour votre attention

La **Stratégie 1 (Transfer Learning BF→HF)** valide la faisabilité de l'approche multi-fidélité : 78,84% sur Test HF, dépassant la borne supérieure, à 55% du coût.

78,84%	**−55% coût**	**2 stratégies**	**5 modèles**
Test HF	vs BL3	testées	comparés